

# Employee Churn

Wahrscheinlichkeit der Mitarbeiterfluktuation  
im BASF Service Hub Berlin

Eric Beier, Lucas Oldenburg, Martin König  
30.01.2022

# Agenda

1. Problemstellung
2. Datengrundlage
3. Deskriptive Analyse
4. Modellauswahl
5. Modellgüte
6. Blick in den Code
7. Modellvergleich
8. Fazit



Hochschule für Technik  
und Wirtschaft Berlin

*University of Applied Sciences*



We create chemistry

# 1. Problemstellung

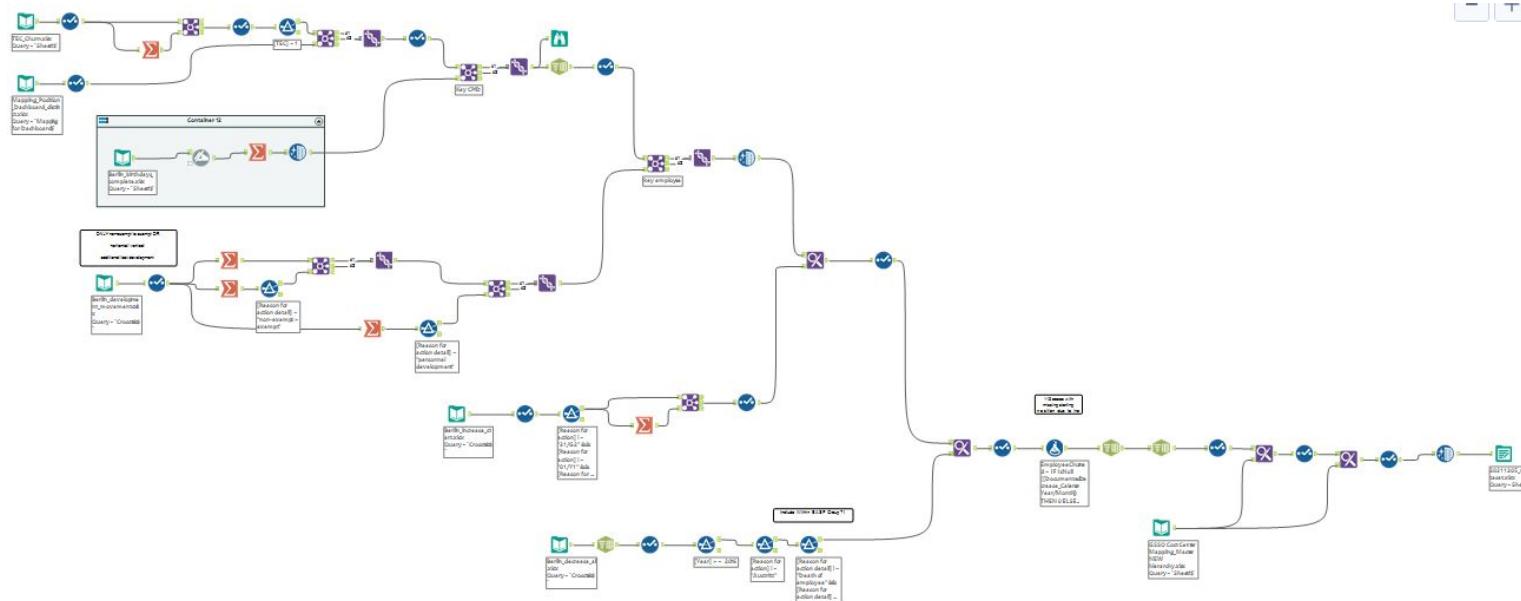


**12-13 % Turnover jährlich**

- Hohe Fluktuation im BASF Service Hub Berlin
- **rechtzeitig** Maßnahmen einleiten
- Nicht im Scope: Sabbatical, Elternzeit, etc.

## 2. Datengrundlage

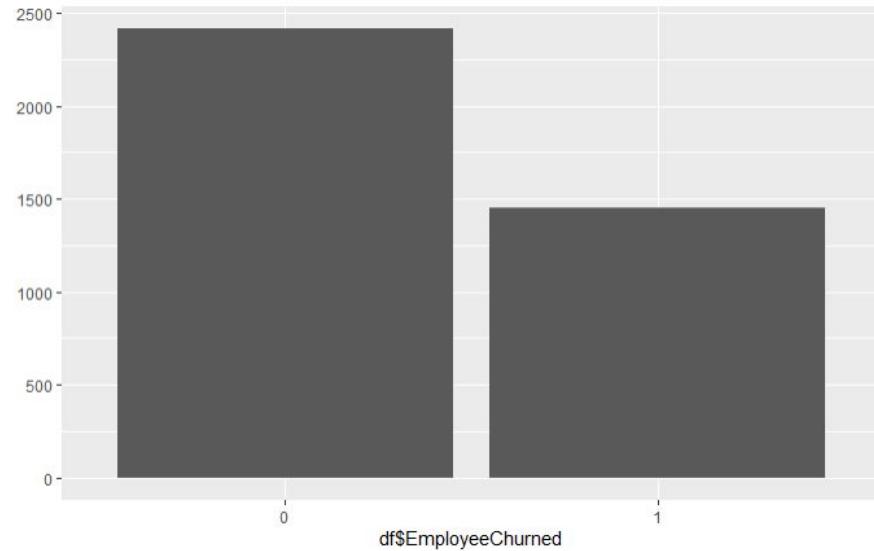
## Daten verbinden und erste Features entwickeln in **Alteryx**



## 2. Datengrundlage

- circa 4000 Datenpunkte
- 41 Merkmale
  - Numerisch: 5
  - Kategorien: 32
  - Daten: 4
- Systemeinführung 2006
- betrachten letzten 6 Jahre
- personalisierte Daten herausgenommen

aktiv: 0 | gegangen: 1



### 3. Deskriptive Analyse

- bereinigt: 14
  - Kostenstelle, Position, Stelle Employee Sub-category...
- verändert: 5
  - Nationality, Last\_Development\_Calendar\_Year...
- angelegt: 5
  - Nationality\_Classification, Month of Service...
- geclustert: 3
  - Nationality\_Classification, Development...

-> final 23 Merkmale

## 4. Modellauswahl

- Supervised Learning - Daten mit Label (Arbeitskraft gegangen/ noch aktiv)
- Decision Tree (Martin)
- Logistic Regression (Lucas)
- Support Vector Machine (Eric)



## 5. Modellgüte

**Güte:** Confusion Matrix und Kostenfunktion

- False Positive - Kosten durch Aufwand für Manager und Arbeitskraft sowie mögliche “vermeidbare” Maßnahmen zum Halten der Arbeitskraft
- False Negative - Kosten durch Rekrutierung und Belastung für das Team

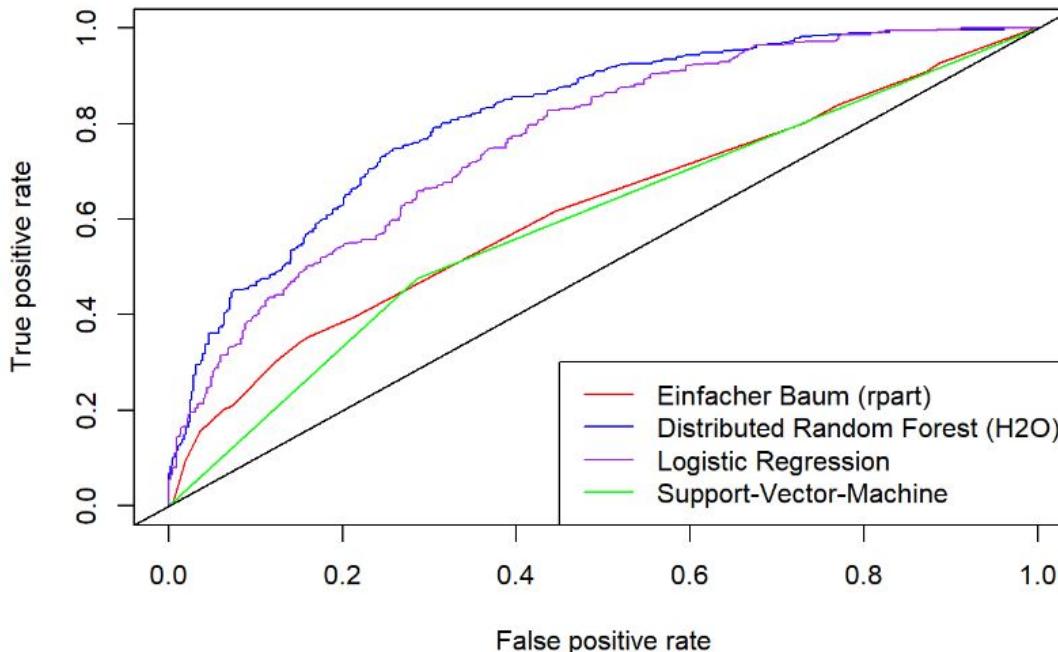
	Mitarbeiter:in geht	Mitarbeiter:in bleibt
Vorhersage Mitarbeiter:in geht	0€	500€
Vorhersage Mitarbeiter:in bleibt	3000€	0€

## 6. Blick in den Code



# 7. Modellvergleich

Vergleich der Algorithmen anhand der einzelnen ROC-Kurven



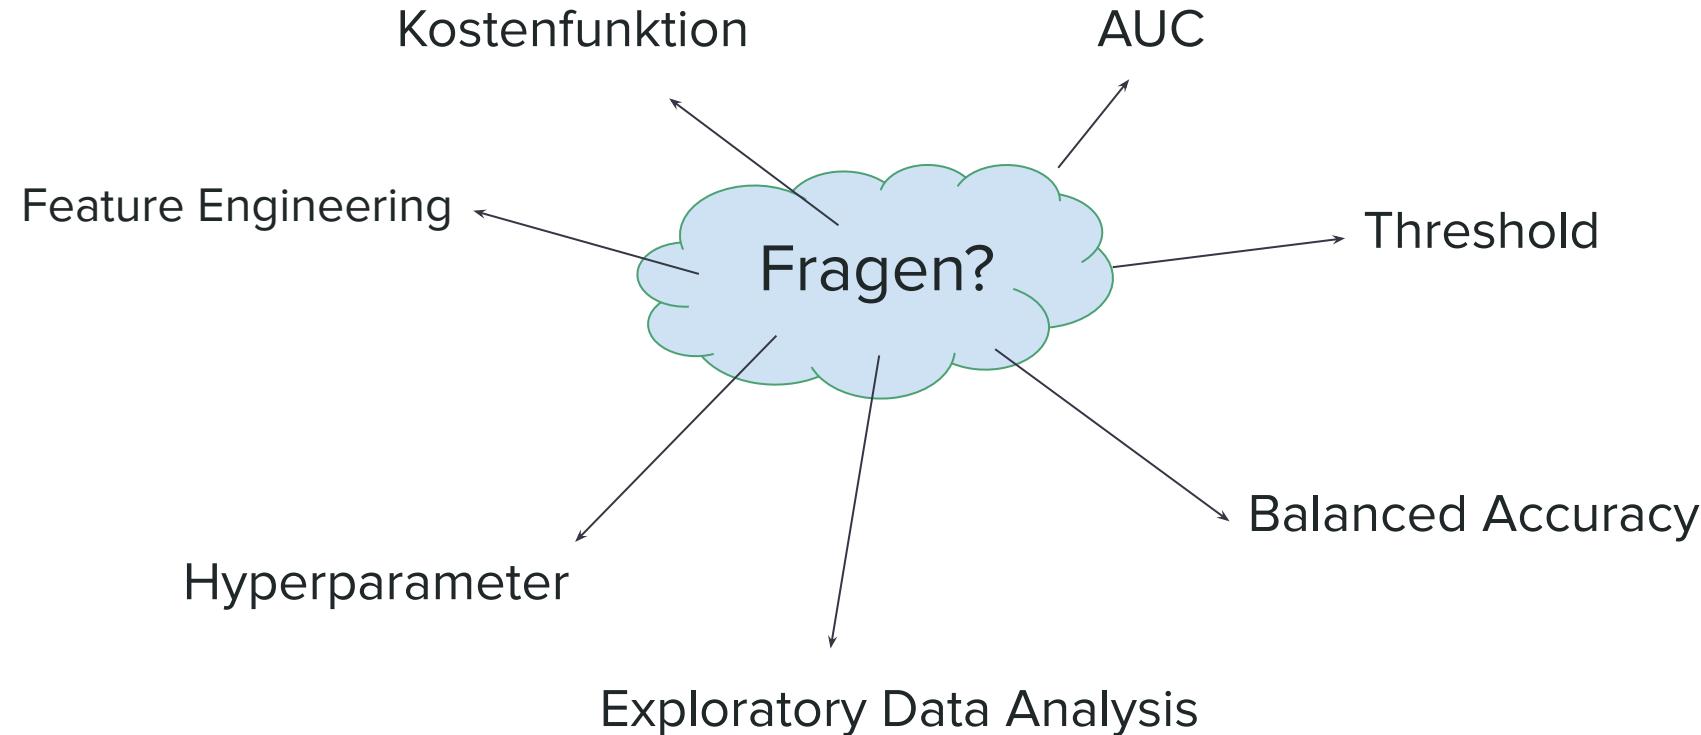
## 7. Modellvergleich

	False-Positive-Rate	Accuracy
Distributed Random Forest	10	65
Logistic Regression	7	59
Support Vector Machine	29	62

	Cost
Distributed Random Forest	240.000
Logistic Regression	233.500

## 8. Fazit und Ausblick





# Präsentationsverteilung

Anmoderation - Eric

1. Problemstellung - Martin
2. Lösungsansatz - Martin
3. Datengrundlage - 1. Martin ab Datenbearbeitung Eric
4. Deskriptive Analyse - 1. Eric dann Lucas
5. Modellauswahl und -güte - Lucas
6. Ausblick - Lucas

Fazit: Datenstruktur (Format) - 80 % data wrangling

Erkenntnis

Nutzen -> optimieren () -> Hyperparameter